

Sveučilište u Mostaru
Fakultet prirodoslovno – matematičkih i odgojnih znanosti
Podatkovna znanost i inženjerstvo

INFORMATIČKI PROJEKT
Predviđanje cijena nekretnina pomoću modela strojnog učenja

Sara Budimir

Mostar, 2026

SAŽETAK

Ovaj seminarski rad bavi se problemom predviđanja cijena nekretnina pomoću popularnih metoda strojnog učenja. Glavni cilj bio je razviti modele koji mogu precizno procijeniti srednju vrijednost kuća u Bostonu, oslanjajući se na kombinaciju geografskih i socio-ekonomskih čimbenika. Za analizu je korišten klasični Boston Housing Dataset, koji kroz varijable poput stope kriminala, prosječnog broja soba i poreznih stopa nudi dublji uvid u faktore koji zapravo diktiraju vrijednost na tržištu nekretnina.

Praktični dio rada započinje eksplorativnom analizom podataka kojom su istražene distribucije ključnih varijabli, njihove međusobne korelacije i skriveni obrasci. Nakon toga, podaci su pripremljeni za samo modeliranje – podijeljeni su na skupove za učenje i testiranje te su standardizirani kako bi se osigurala stabilnost algoritama.

Za samo predviđanje cijena odabrana su dva različita pristupa: linearni, kroz Ridge regresiju, te nelinearni ansambl algoritam, odnosno Random Forest regresor. Kvantitativna evaluacija i usporedba modela provedena je pomoću standardnih metrika: srednje apsolutne pogreške (MAE), korijena srednje kvadratne pogreške (RMSE) i koeficijenta determinacije (R^2).

Rezultati analize pokazali su da Random Forest model značajno nadmašuje Ridge regresiju, ostvarujući manju pogrešku i osjetno veću točnost predikcije. U konačnici, rad potvrđuje kako modeli strojnog učenja mogu uspješno prepoznati i modelirati kompleksne, nelinearne odnose između karakteristika mikrolokacije i same cijene nekretnina.

SADRŽAJ

1. UVOD	1
2. RELATED WORK.....	2
3. PODACI.....	3
3.1 Izvor podataka.....	3
3.2 Opis atributa.....	3
4. METODOLOGIJA.....	4
4.1 Priprema i predprocesiranje podataka	4
4.2 Exploratory Data Analysis (EDA).....	4
4.3 Podjela podataka i skaliranje	10
4.4 Modeli strojnog učenja	11
4.4.1 Ridge regresija	11
4.4.1 Random Forest regresija.....	12
4.5 Evaluacija modela	13
5. EKSPERIMENTI.....	14
6. REZULTATI.....	16
7. RASPRAVA	18
7.1. Dubinska analiza performansi modela	18
7.2. Interpretacija važnosti značajki i utjecaj outliera	18
8. ZAKLJUČAK.....	20
9. SLIKE	21
10. LITERATURA.....	22

1. UVOD

Predviđanje cijena nekretnina jedan je od najčešćih problema u analizi podataka i strojnog učenja, jer ima direktnu primjenu u stvarnom životu. Cijena nekretnine ne ovisi samo o jednoj stvari, nego o velikom broju različitih čimbenika koji zajedno utječu na njezinu vrijednost. Ti čimbenici mogu biti vezani uz lokaciju, stanje okoline, socio-ekonomske uvjete stanovništva, infrastrukturu i druge karakteristike područja.

U stvarnom svijetu procjena vrijednosti nekretnina često se radi ručno ili na temelju jednostavnih pravila, što može dovesti do netočnosti i subjektivnih procjena. Zbog toga se u modernim sustavima sve više koriste metode strojnog učenja koje mogu analizirati velike količine podataka i pronaći obrasce koji nisu odmah vidljivi čovjeku.

Ovaj projekt temelji se na analizi skupa podataka Boston Housing Dataset koji sadrži informacije o različitim karakteristikama područja Bostona. Svaki zapis u skupu podataka opisuje jedno područje i njegove karakteristike poput stope kriminala, prosječnog broja soba u kućama, udaljenosti od centara grada i drugih socio-ekonomskih pokazatelja.

Cilj ovog rada je bolje razumjeti kako različite varijable utječu na cijenu nekretnina te kako se ti odnosi mogu prikazati pomoću modela strojnog učenja. Posebna pažnja posvećena je analizi podataka i razumijevanju njihovih odnosa prije samog modeliranja.

U okviru rada korištene su osnovne metode obrade podataka, uključujući čišćenje, pregled statistike i analizu odnosa između varijabli. Nakon toga su primijenjeni modeli strojnog učenja koji uče iz podataka i pokušavaju predvidjeti vrijednost nekretnina na temelju ulaznih značajki.

Ovaj rad pokazuje kako se uz pomoć suvremenih metoda može bolje razumjeti kompleksnost tržišta nekretnina te kako podaci mogu pomoći u donošenju boljih odluka.

2. RELATED WORK

Predviđanje cijena nekretnina u literaturi se najčešće promatra kao regresijski problem u kojem se modelira odnos između više ulaznih varijabli i jedne kontinuirane izlazne varijable. Zbog svoje jednostavne formulacije, ali i potencijalno složenih odnosa u podacima, ovaj problem često se koristi kao referentni primjer u području nadziranog učenja.

U ranijim pristupima dominirali su linearni ekonometrijski modeli, pri čemu je standardni pristup bio hedoničko modeliranje cijena (engl. Hedonic Pricing Method). Ovaj pristup pretpostavlja da se ukupna vrijednost nekretnine može dekomponirati na doprinos njezinih pojedinačnih karakteristika, a najčešće korištena metoda procjene parametara bila je metoda najmanjih kvadrata (OLS). Iako su takvi modeli interpretabilni, njihova učinkovitost je ograničena u slučajevima prisutnosti multikolinearnosti i nelinearnih odnosa među varijablama, što može dovesti do nestabilnih procjena i smanjene prediktivne točnosti.

Kako bi se adresirala ta ograničenja, razvijene su metode regularizacije poput Ridge i Lasso regresije, koje uvođenjem kaznenih članova smanjuju varijancu modela i poboljšavaju stabilnost procjena, uz očuvanje interpretabilnosti linearnih modela.

Paralelno s time, razvojem strojnog učenja sve veću primjenu dobivaju nelinearni modeli temeljeni na stablima odlučivanja. Ansambl metode, poput Random Forest algoritma, kombiniraju više pojedinačnih modela kako bi se postigla veća robusnost, smanjila pogreška predikcije te bolje modelirali kompleksni nelinearni odnosi i interakcije između varijabli. Takvi modeli ne zahtijevaju pretpostavku o linearnoj vezi između ulaznih i izlaznih varijabli te se pokazuju posebno učinkovitima na skupovima podataka s izraženim nelinearnostima i utjecajem ekstremnih vrijednosti.

U suvremenoj literaturi usporedna analiza linearnih regulariziranih modela i ansambl metoda predstavlja standardni pristup evaluaciji regresijskih problema. Na taj se način omogućuje jasna usporedba interpretabilnijih, ali jednostavnijih modela s kompleksnijim, ali prediktivno snažnijim nelinearnim pristupima, što doprinosi boljem razumijevanju ponašanja tržišta nekretnina i strukture podataka.

3. PODACI

3.1 Izvor podataka

Korišten je Boston Housing Dataset (Understanding Urban Real Estate: The Boston Housing Dataset), koji predstavlja jedan od najpoznatijih skupova podataka u području strojnog učenja za regresijske probleme. Dataset je preuzet iz javno dostupnih repozitorija za analizu podataka i strojno učenje, Kaggle platforme (<https://www.kaggle.com/datasets/arunjangir245/boston-housing-dataset>).

Skup podataka originalno je povezan s istraživanjem tržišta nekretnina u području Bostona te sadrži socio-ekonomske i geografske varijable koje opisuju karakteristike pojedinih urbanih zona.

Dataset se sastoji od jedne tablice podataka u kojoj svaka instanca predstavlja jednu promatranu regiju. Varijable uključuju faktore poput stope kriminala, udjela industrijskih zona, broja soba, poreznih stopa i drugih karakteristika koje utječu na cijenu nekretnina. Ciljna varijabla predstavlja srednju vrijednost nekretnina (MEDV).

3.2 Opis atributa

Originalni skup podataka Boston Housing Dataset sadrži 13 ulaznih varijabli i jednu ciljnu varijablu koja predstavlja srednju vrijednost nekretnina (MEDV). Svaki atribut opisuje socio-ekonomske i fizičke karakteristike promatrane regije.

Atribut	Opis
CRIM	Stopa kriminala po stanovniku
ZN	Udio stambenih zona za velike parcele
INDUS	Udio poslovnih površina
CHAS	Blizina rijeke Charles (1 = da, 0 = ne)
NOX	Koncentracija dušikovih oksida
RM	Prosječan broj soba po stanu
AGE	Udio starih zgrada
DIS	Udaljenost do centara zaposlenja
RAD	Pristupačnost autocestama
TAX	Porezna stopa po nekretnini
PTRATIO	Omjer učenika i učitelja
B	Udio stanovništva afroameričkog podrijetla
LSTAT	Postotak stanovništva nižeg socio-ekonomskog statusa
MEDV	Srednja vrijednost nekretnina (ciljna varijabla)

4. METODOLOGIJA

Metodologija ovog rada obuhvaća nekoliko faza: predprocesiranje podataka, podjelu podataka na skup za učenje i testiranje, primjenu standardizacije te izgradnju i evaluaciju modela strojnog učenja.

4.1 Priprema i predprocesiranje podataka

U prvom koraku izvršena je osnovna analiza kvalitete podataka. Provjereno je postojanje nedostajućih vrijednosti u skupu podataka Boston Housing Dataset. Rezultati su pokazali da u nijednoj varijabli ne nedostaju vrijednosti, što omogućuje izravnu primjenu modela bez potrebe za dodatnim imputacijama.

Nakon toga izvršena je osnovna statistička analiza podataka (mean, std, min, max) kako bi se dobio uvid u raspodjelu varijabli.

Posebna pažnja posvećena je ciljnoj varijabli MEDV, koja predstavlja srednju vrijednost nekretnina. Analizom je utvrđeno da se većina vrijednosti nalazi u rasponu 17–25 (u tisućama dolara), uz prisutnost ekstremnih vrijednosti (outliera) koji dosežu maksimalnu vrijednost 50.

4.2 Exploratory Data Analysis (EDA)


U ovom dijelu rada napravljena je osnovna analiza podataka kako bi se bolje razumjelo kako izgleda skup podataka i kakvi se odnosi nalaze između varijabli. Prvo je proučavana ciljna varijabla MEDV, koja predstavlja cijenu kuća. To je napravljeno pomoću histograma i boxplota, koji prikazuju kako su vrijednosti raspoređene.

Na temelju tih grafova može se vidjeti da se većina cijena kuća nalazi u srednjem rasponu, dok manji broj vrijednosti odstupa i ide prema višim ili nižim cijenama. Također se vidi da distribucija nije potpuno ravnomjerna, nego postoji blaga asimetrija, što znači da su neke vrijednosti češće od drugih.

Nakon toga je analizirano kako su pojedine ulazne varijable povezane s cijenom kuća. To je napravljeno pomoću korelacije, koja pokazuje koliko je neka varijabla povezana s promjenom cijene. Rezultati su pokazali da varijabla RM (prosječan broj soba) ima najjaču pozitivnu vezu s cijenom, što znači da kuće s više soba uglavnom imaju veću cijenu.


S druge strane, varijabla LSTAT (udio stanovništva nižeg socio-ekonomskog statusa) ima najjaču negativnu vezu s cijenom, što znači da su cijene kuća obično niže u područjima gdje je taj udio veći.

Na kraju je prikazan i odnos između RM i MEDV pomoću scatter grafa. Taj graf pokazuje jasan trend da s povećanjem broja soba raste i cijena kuće, što potvrđuje da je ta varijabla vrlo važna za predviđanje cijena.




Slika 1. Distribucija cijena kuća MEDV

Može se uočiti da se većina vrijednosti nalazi u rasponu srednjih cijena, dok je manji broj nekretnina s višim vrijednostima. Distribucija je blago asimetrična, što ukazuje na prisutnost ekstremnih vrijednosti (outliera) na višem kraju raspona.




Slika 2. Distribucija cijena kuća i outlieri (MEDV)

Može se uočiti prisutnost većeg broja outliera, posebno na višem kraju distribucije, gdje se vrijednosti približavaju maksimalnoj granici od 50. Također se vidi da su većina vrijednosti koncentrirane u srednjem rasponu, dok manji broj odstupa od uobičajenih vrijednosti.




Slika 3. Korelacija varijabli s MEDV (cijenom kuće)

Može se uočiti da varijabla RM ima najjaču pozitivnu korelaciju s cijenom kuća, dok LSTAT ima najjaču negativnu korelaciju. Ostale varijable imaju slabiji ili umjereni utjecaj na cijenu nekretnina.




Slika 4. Utjecaj socioekonomskog statusa (LSTAT) na cijenu kuće (MEDV)

Grafikon prikazuje odnos između udjela stanovništva nižeg socioekonomskog statusa (LSTAT) i cijene nekretnina (MEDV), jasno ukazujući na snažnu negativnu korelaciju. Crvena regresijska linija potvrđuje izražen silazni trend, što znači da cijene kuća značajno opadaju u četvrtima s većim postotkom siromašnijeg stanovništva. Na samom vrhu uočljivo je i umjetno ograničenje podataka, gdje je maksimalna vrijednost nekretnina fiksirana na 50 tisuća dolara.




Slika 5. Utjecaj broja soba (RM) na cijenu kuće

Grafikon prikazuje odnos između prosječnog broja soba po stambenoj jedinici (RM) i cijene nekretnina (MEDV), ukazujući na snažnu pozitivnu korelaciju. Crvena regresijska linija jasno potvrđuje uzlazni trend koji pokazuje da veći broj soba izravno utječe na rast vrijednosti kuća. Prema tablici, prosječan broj soba iznosi oko 6.28 (uz medijalnu cijenu od 22.53 tisuće dolara), dok se na vrhu ponovno uočava skupina nekretnina s maksimalnom, ograničenom vrijednošću od 50 tisuća dolara bez obzira na veličinu.



Slika 6. Utjecaj blizine rijeke (CHAS) na cijenu kuće

Grafikon kroz box plot uspoređuje cijene nekretnina ovisno o njihovoj poziciji uz rijeku Charles (CHAS). Vidljivo je da nekretnine s pogledom na rijeku (CHAS = 1) imaju primjetno višu medijalnu vrijednost i općenito pomaknut cjenovni razred prema gore u odnosu na ostale lokacije. Iako je broj kuća uz samu rijeku statistički znatno manji (što potvrđuje podatak da je prosjek varijable CHAS svega 0.069), blizina vode jasno djeluje kao luksuzni faktor koji podiže donju i gornju granicu cijene kvartala.



Slika 7. Utjecaj varijabli na cijenu kuće (korelacija s MEDV)

Grafikon i pripadajuća tablica prikazuju cjelovit pregled koeficijenata linearne korelacije svih nezavisnih varijabli u odnosu na ciljnu vrijednost nekretnina (MEDV). Vizualizacija jasno identificira prosječan broj soba (RM, 0.70) kao dominantan pozitivan čimbenik, dok socioekonomski status (LSTAT, -0.74) i omjer učenika i nastavnika (PTRATIO, -0.51) predvode skupinu varijabli s izraženim negativnim utjecajem. Ovakav raspored korelacija sugerira da će linearni modeli primarno hvatati utjecaj prostranosti objekta i socijalne komponente kvarta, dok varijable poput blizine rijeke (CHAS) i starosti objekata (AGE) imaju sekundarni značaj u linearnom kontekstu.

4.3 Podjela podataka i skaliranje

U ovom koraku skup podataka je podijeljen na dva dijela: trening i test skup. Podjela je napravljena u omjeru 80% podataka za učenje modela i 20% podataka za testiranje.

Trening skup se koristi za to da model “uči” iz podataka, odnosno da pronalazi odnose između ulaznih varijabli i cijene kuća. Test skup se koristi kasnije kako bi se provjerilo koliko dobro model radi na novim, neviđenim podacima koje nije vidio tijekom učenja. Na taj način se dobiva realnija procjena kvalitete modela.

Nakon podjele podataka napravljena je i standardizacija ulaznih varijabli pomoću metode `StandardScaler`. To znači da su sve varijable pretvorene u istu skalu, kako bi imale sličan raspon vrijednosti. Ovo je važno jer neki modeli bolje rade kada su svi ulazni podaci na istoj razini.

Važno je napomenuti da se standardizacija računa samo na temelju trening skupa, a zatim se ista transformacija primjenjuje i na test skup. Time se izbjegava “curenje informacija”, odnosno situacija u kojoj bi model slučajno dobio informacije iz test podataka tijekom učenja, što bi moglo dati dobre rezultate.

4.4 Modeli strojnog učenja

4.1.1 Ridge regresija

Ridge regresija predstavlja proširenje klasične linearne regresije koje je razvijeno s ciljem ublažavanja problema multikolinearnosti među ulaznim varijablama te smanjenja rizika od prenaučivosti modela (engl. overfitting). U situacijama kada su prediktorske varijable međusobno snažno korelirane, procjene koeficijenata dobivene metodom najmanjih kvadrata mogu postati nestabilne. Kao posljedica toga, i male promjene u podacima za učenje mogu uzrokovati značajne promjene vrijednosti procijenjenih parametara modela.

Kako bi se povećala stabilnost modela, Ridge regresija uvodi postupak regularizacije poznat kao L2 regularizacija. Za razliku od standardne linearne regresije, koja minimizira isključivo sumu kvadratnih pogrešaka između stvarnih i predviđenih vrijednosti, Ridge regresija u funkciju cilja dodaje dodatni kazneni član. Taj član ovisi o sumi kvadrata koeficijenata modela te služi za ograničavanje njihove veličine.

Funkcija koja se minimizira prikazana je sljedećom jednadžbom:

$$\text{Minimiziraj } \sum_{i=1}^n (y_i - \hat{y}_i)^2 + \alpha \sum_{j=1}^m w_j^2$$

U navedenoj jednadžbi parametar (α) predstavlja hiperparametar regularizacije koji određuje jačinu kazne primijenjene na koeficijente modela. Kada je vrijednost parametra ($\alpha = 0$), Ridge regresija postaje ekvivalentna klasičnoj linearnoj regresiji. Povećanjem vrijednosti parametra (α) raste i utjecaj regularizacijskog člana, zbog čega se koeficijenti modela postupno smanjuju prema nuli, iako nikada ne postaju potpuno jednaki nuli.

Smanjivanjem veličine koeficijenata model postaje manje osjetljiv na šum i slučajne varijacije prisutne u podacima za učenje. Time se namjerno uvodi određena razina pristranosti (engl. bias), ali se istodobno značajno smanjuje varijanca modela. Takav kompromis često rezultira boljom sposobnošću generalizacije na novim podacima, što Ridge regresiju čini prikladnim izborom za analizu složenih skupova podataka, uključujući modele za predviđanje cijena nekretnina.

4.2.1 Random Forest regresija

Random Forest regresija (šuma slučajnih stabala) predstavlja nelinearni algoritam strojnog učenja koji pripada skupini ansambl metoda (engl. Ensemble Learning). Temeljna ideja ansambl pristupa jest kombiniranje većeg broja pojedinačnih modela kako bi se postigla veća točnost, stabilnost i sposobnost generalizacije u odnosu na korištenje jednog modela. U slučaju Random Forest algoritma, osnovne komponente ansambla su stabla odlučivanja, čije se pojedinačne predikcije kombiniraju u konačan rezultat.

Rad algoritma temelji se na dvama ključnim mehanizmima: baggingu (engl. Bootstrap Aggregating) i slučajnom odabiru značajki.

Prvi mehanizam, bagging, podrazumijeva generiranje više različitih podskupova podataka iz izvornog skupa za učenje. Svaki podskup nastaje metodom uzorkovanja s ponavljanjem (engl. bootstrap sampling), pri čemu se isti zapis može pojaviti više puta, dok neki zapisi mogu izostati iz pojedinog podskupa. Na svakom tako dobivenom podskupu trenira se zasebno stablo odlučivanja.

Drugi mehanizam odnosi se na slučajni odabir značajki tijekom izgradnje stabla. Prilikom svakog cijepanja čvora algoritam ne razmatra sve dostupne ulazne varijable, već samo njihov nasumično odabrani podskup. Time se smanjuje međusobna sličnost stabala te povećava raznolikost modela, što pozitivno utječe na konačnu točnost predviđanja.

Kod predviđanja vrijednosti za novi primjer, podaci prolaze kroz sva izgrađena stabla u šumi. Svako stablo generira vlastitu procjenu ciljne varijable, a konačna predikcija dobiva se izračunavanjem aritmetičke sredine svih pojedinačnih predikcija.

Konačna vrijednost predikcije računa se prema izrazu:

$$\hat{y} = \frac{1}{N} \sum_{k=1}^N T_k(x)$$

gdje ($T_k(x)$) predstavlja predikciju (k)-tog stabla, a (N) ukupan broj stabala unutar šume.

Jedna od najvažnijih prednosti Random Forest algoritma jest njegova otpornost na prenaučenosť (engl. overfitting), koja je često prisutna kod pojedinačnih stabala odlučivanja. Osim toga, algoritam uspješno modelira složene i nelinearne odnose između ulaznih varijabli i ciljne vrijednosti. Zahvaljujući toj sposobnosti može prepoznati obrasce koje linearni modeli ne mogu opisati, primjerice situacije u kojima vrijednost nekretnine ne raste proporcionalno broju soba, već se značajno povećava tek nakon dostizanja određenog praga. Zbog navedenih karakteristika Random Forest predstavlja jedan od najčešće korištenih algoritama za regresijske zadatke u području prediktivne analitike i strojnog učenja.

4.5 Evaluacija modela

Metrika	Opis
RMSE (Root Mean Squared Error)	Mjeri prosječnu pogrešku predikcije. Veće greške više kažnjava nego male, pa je osjetljiv na veća odstupanja.
MAE (Mean Absolute Error)	Prikazuje prosječnu apsolutnu razliku između stvarnih i predviđenih vrijednosti. Lakše se interpretira jer je u istoj jedinici kao i ciljna varijabla.
R² (koeficijent determinacije)	Pokazuje koliko dobro model objašnjava varijabilnost podataka. Vrijednosti bliže 1 znače bolji model.

5. EKSPERIMENTI

5.1. Opis eksperimenata

Eksperimentalni dio rada proveden je u interaktivnom razvojnom okruženju Jupyter Notebook, uz primjenu programskog jezika Python te biblioteke Scikit-Learn, koja predstavlja jedan od standardnih alata u području strojnog učenja. Kako bi se osigurala objektivnost, dosljednost i usporedivost rezultata, svi modeli trenirani su i evaluirani na istom skupu podataka.

Izvorni skup podataka podijeljen je u omjeru 80 % prema 20 %, pri čemu je veći dio korišten za treniranje modela, dok je manji dio izdvojen isključivo za testiranje i procjenu sposobnosti generalizacije modela na neviđenim podacima.

U okviru eksperimenta analizirana su dva regresijska pristupa:

Ridge regresija (Ridge Regression) predstavlja linearni model koji koristi L2 regularizaciju s ciljem smanjenja prenaučivosti (engl. overfitting) i stabilizacije procjene koeficijenata u slučaju multikolinearnosti. U ovom radu korištena je s podrazumijevanim parametrima, te služi kao osnovni referentni model (baseline) za usporedbu.

Random Forest regresija (Random Forest Regression) predstavlja nelinearni ansambl model (engl. ensemble method) temeljen na skupu stabala odlučivanja. U eksperimentu je model konfiguriran s 100 stabala ($n_estimators = 100$), čime se omogućuje bolja sposobnost modeliranja složenih i nelinearnih odnosa u podacima.

Odabrana kombinacija modela omogućuje izravnu usporedbu performansi između jednostavnijeg linearnog pristupa i kompleksnijeg nelinearnog ansambl modela, pri čemu se svi modeli evaluiraju na identičnom testnom skupu podataka.

5.2. Evaluacijske metrike

Za kvantitativnu procjenu uspješnosti i preciznosti predikcija implementiranih modela korištene su standardne statističke metrike u regresijskoj analizi.

Srednja apsolutna pogreška (MAE – Mean Absolute Error) daje uvid u prosječnu veličinu pogreške predikcija, neovisno o njihovom smjeru. Vrijednosti se interpretiraju u istim mjernim jedinicama kao i ciljna varijabla, što olakšava njihovu praktičnu interpretaciju.

Korijen srednje kvadratne pogreške (RMSE – Root Mean Squared Error) predstavlja metriku koja dodatno penalizira veća odstupanja, budući da uključuje kvadriranje pogrešaka. Zbog toga je posebno osjetljiva na velike pogreške u pojedinim primjerima te omogućuje uvid u stabilnost modela.

Koeficijent determinacije (R^2) prikazuje udio varijance zavisne varijable koji je objašnjen modelom. Ova metrika omogućuje procjenu ukupne kvalitete modela te njegove sposobnosti da objasni strukturu podataka.

Kombinacijom navedenih triju metrika dobiva se cjelovit i uravnotežen uvid u performanse modela, što omogućuje objektivnu usporedbu različitih pristupa i donošenje zaključka o njihovoj učinkovitosti u kontekstu promatranog problema.

6. REZULTATI

6.1 Usporedba modela


Model	RMSE	MAE	R ²
Ridge regresija	4.93	3.19	0.67
Random Forest	2.95	2.04	0.88

Rezultati pokazuju jasnu razliku u performansama između modela. Random Forest regresija postiže znatno niže vrijednosti pogreške (RMSE i MAE) u odnosu na Ridge regresiju, što ukazuje na preciznije predikcije cijena nekretnina.

Također, koeficijent determinacije (R^2) je viši kod Random Forest modela, što znači da ovaj model bolje objašnjava varijabilnost podataka i uspješnije uči kompleksne odnose između ulaznih varijabli i ciljane vrijednosti.


6.2 Grafovi usporedbe modela

Graf prikazuje odnos između stvarnih i predviđenih cijena kuća kod Ridge regresije. Crvena dijagonalna linija predstavlja idealnu predikciju, odnosno situaciju u kojoj bi model potpuno točno predvidio vrijednost nekretnine. Može se primijetiti da dio predikcija odstupa od idealne linije, posebno kod viših cijena kuća, što ukazuje na određenu pogrešku modela. Ipak, vidljiv je opći linearni trend, što potvrđuje da model uspijeva prepoznati osnovne odnose između varijabli i cijene nekretnina.



Slika 8. Ridge regresija

Graf prikazuje usporedbu stvarnih i predviđenih cijena pomoću Random Forest modela. Većina točaka nalazi se bliže idealnoj liniji u odnosu na Ridge regresiju, što pokazuje da model daje preciznije procjene cijena nekretnina. Random Forest bolje prepoznaje složenije i nelinearne odnose između varijabli, zbog čega ostvaruje manju pogrešku i veću točnost predikcije. Unatoč tome, vidljiva su manja odstupanja kod ekstremnih vrijednosti, što je očekivano kod stvarnih podataka.



Slika 9. Random Forest

Usporedbom grafova može se vidjeti da Random Forest model daje predikcije koje su bliže stvarnim vrijednostima u odnosu na Ridge regresiju. To potvrđuju i evaluacijske metrike, gdje Random Forest ostvaruje manji RMSE i MAE te veći R^2 koeficijent.

7. RASPRAVA

7.1. Dubinska analiza performansi modela

Usporedba rezultata evaluacijskih metrika prikazanih u poglavlju 6 jasno pokazuje prednost nelinearnog pristupa u modeliranju cijena nekretnina. Ridge regresija ostvarila je koeficijent determinacije (R^2) od 0,67, što znači da model uspijeva objasniti približno 67 % varijabiliteta cijena kuća u Bostonu. Iako se radi o zadovoljavajućem rezultatu za linearni model, srednja apsolutna pogreška (MAE) od 3,19, odnosno približno 3.190 dolara, ukazuje na određena ograničenja linearnog pristupa te na pojavu podprilagođenosti modela (engl. underfitting).

S druge strane, Random Forest model ostvario je znatno bolje rezultate. Koeficijent determinacije iznosi 0,88, što znači da model objašnjava čak 88 % varijance ciljne varijable. Također, korijen srednje kvadratne pogreške (RMSE) smanjen je na 2,95, što potvrđuje veću preciznost predviđanja u odnosu na Ridge regresiju.

Razlog ovakve razlike u performansama leži u prirodi podataka. Odnosi između čimbenika koji utječu na cijene nekretnina često nisu linearni. Primjerice, utjecaj stope kriminala (CRIM) ili razine onečišćenja zraka (NOX) na vrijednost nekretnine može imati pragovni karakter. Dok niže razine zagađenja kupci često zanemaruju, više razine mogu uzrokovati značajan pad tržišne vrijednosti nekretnine.

Ridge regresija pokušava opisati takve odnose jednom linearnom funkcijom, zbog čega ne uspijeva u potpunosti obuhvatiti složenost podataka. Nasuprot tome, Random Forest model dijeli prostor značajki na manje regije te na taj način uspješnije prepoznaje nelinearne obrasce i interakcije među varijablama. Zbog svoje sposobnosti modeliranja složenih odnosa, Random Forest postiže veću točnost i pouzdanost u predviđanju cijena nekretnina.

7.2. Interpretacija važnosti značajki i utjecaj outliera

Analiza važnosti značajki i distribucije podataka omogućila je identifikaciju najvažnijih čimbenika koji utječu na cijene nekretnina u promatranom skupu podataka. Među svim varijablama posebno su se istaknule RM (prosječan broj soba po stambenoj jedinici) i LSTAT (udio stanovništva nižeg socioekonomskog statusa), koje predstavljaju najznačajnije prediktore tržišne vrijednosti nekretnina.

Varijabla RM pokazuje pozitivan utjecaj na cijenu nekretnine, budući da veći broj soba najčešće ukazuje na veću stambenu površinu, višu razinu komfora te veću tržišnu vrijednost objekta. S druge strane, varijabla LSTAT ima negativan utjecaj na cijenu, jer odražava socioekonomske karakteristike naselja te

može poslužiti kao pokazatelj društvenog statusa, kvalitete okruženja i privlačnosti lokacije za potencijalne kupce.

Tijekom analize uočen je i specifičan fenomen vezan uz distribuciju ciljne varijable. Na grafikonima stvarnih i predviđenih vrijednosti (Slike 8 i 9) primjetna je koncentracija podataka na vrijednosti 50 (u tisućama dolara), koja predstavlja gornju granicu dostupnih podataka. Naime, u izvornom skupu podataka svim nekretninama čija je stvarna vrijednost prelazila navedeni iznos dodijeljena je maksimalna vrijednost od 50. Kao posljedica toga, na grafikonima se pojavljuje horizontalna linija točaka koja označava umjetno ograničenje vrijednosti.

Takvo ograničenje predstavlja izazov za linearne modele poput Ridge regresije. Budući da linearni model pretpostavlja kontinuirani linearni odnos između ulaznih i izlaznih varijabli, teško se prilagođava situacijama u kojima postoje nagli prekidi ili ograničenja u distribuciji podataka. Zbog toga dolazi do povećanja pogreške predviđanja u području najviših vrijednosti nekretnina.

Nasuprot tome, Random Forest model uspješnije se nosi s ovakvim karakteristikama podataka. Njegova struktura temeljena na stablu odlučivanja omogućuje modeliranje složenih i nelinearnih odnosa te prirodno prilagođavanje granicama koje postoje u podacima. Zbog toga ostvaruje preciznija predviđanja i bolje rezultate evaluacijskih metrika u odnosu na linearni pristup.

8. ZAKLJUČAK

U ovom radu analiziran je problem predviđanja cijena nekretnina pomoću metoda strojnog učenja na primjeru Boston Housing Dataset skupa podataka. Tijekom rada provedena je analiza i priprema podataka, istraživanje odnosa između varijabli te izgradnja i usporedba različitih modela za regresiju.

Rezultati su pokazali da socio-ekonomski i geografski čimbenici imaju značajan utjecaj na cijenu nekretnina. Posebno su se izdvojile varijable RM i LSTAT, koje su pokazale najjaču povezanost s ciljnom varijablom MEDV.

U eksperimentalnom dijelu rada uspoređeni su Ridge regresija i Random Forest model. Random Forest ostvario je bolje rezultate u svim evaluacijskim metrikama, uz manju pogrešku predikcije i veći koeficijent determinacije. Time je potvrđeno da nelinearni modeli mogu uspješnije opisati složene odnose prisutne u podacima.

Kroz rad je prikazano kako metode strojnog učenja mogu pomoći u analizi tržišta nekretnina i predviđanju cijena na temelju dostupnih podataka. Takvi modeli mogu imati korisnu primjenu u financijama, procjeni vrijednosti nekretnina i sustavima za podršku odlučivanju.

Kao mogući smjer budućih istraživanja, model bi se mogao proširiti korištenjem većih i modernijih skupova podataka koji uključuju dodatne informacije o lokaciji, stanju objekta i tržišnim uvjetima. Također, mogla bi se ispitati primjena naprednijih modela poput XGBoost, Gradient Boosting ili neuronskih mreža kako bi se dodatno poboljšala točnost predikcije.

9. SLIKE

Slika 1. Distribucija cijena kuća MEDV.....	5
Slika 2. Distribucija cijena kuća i outlieri (MEDV)	5
Slika 3. Korelacija varijabli s MEDV (cijenom kuće)	6
Slika 4. Utjecaj socioekonomskog statusa (LSTAT) na cijenu kuće (MEDV)	6
Slika 5. Utjecaj broja soba (RM) na cijenu kuće	7
Slika 6. Utjecaj blizine rijeke (CHAS) na cijenu kuće.....	8
Slika 7. Utjecaj varijabli na cijenu kuće (korelacija s MEDV).....	9
Slika 8. Ridge regresija.....	16
Slika 9. Random Forest.....	17

10.LITERATURA

Boston Housing Dataset. Kaggle platforma.

<https://www.kaggle.com/datasets/arunjangir245/boston-housing-dataset>

Scikit-Learn Documentation.

<https://scikit-learn.org/stable/>

Scikit-Learn – Supervised Learning Documentation.

https://scikit-learn.org/stable/supervised_learning.html

Géron, A. *Hands-On Machine Learning with Scikit-Learn, Keras & TensorFlow*. O'Reilly Media, 2022.