

Sveučilište u Mostaru
Fakultet prirodoslovno – matematičkih i odgojnih znanosti
Podatkovna znanost i inženjerstvo

INFORMATIČKI PROJEKT
Predviđanje cijena nekretnina pomoću modela strojnog učenja

Sara Budimir

Mostar, 2026

SAŽETAK

Ovaj seminarski rad bavi se problemom predviđanja cijena nekretnina pomoću popularnih metoda strojnog učenja. Glavni cilj bio je razviti modele koji mogu precizno procijeniti srednju vrijednost kuća u Bostonu, oslanjajući se na kombinaciju geografskih i socio-ekonomskih čimbenika. Za analizu je korišten klasični Boston Housing Dataset, koji kroz varijable poput stope kriminala, prosječnog broja soba i poreznih stopa nudi dublji uvid u faktore koji zapravo diktiraju vrijednost na tržištu nekretnina.

Praktični dio rada započinje eksplorativnom analizom podataka kojom su istražene distribucije ključnih varijabli, njihove međusobne korelacije i skriveni obrasci. Nakon toga, podaci su pripremljeni za samo modeliranje – podijeljeni su na skupove za učenje i testiranje te su standardizirani kako bi se osigurala stabilnost algoritama.

Za samo predviđanje cijena odabrana su dva različita pristupa: linearni, kroz Ridge regresiju, te nelinearni ansambl algoritam, odnosno Random Forest regresor. Kvantitativna evaluacija i usporedba modela provedena je pomoću standardnih metrika: srednje apsolutne pogreške (MAE), korijena srednje kvadratne pogreške (RMSE) i koeficijenta determinacije (R^2).

Rezultati analize pokazali su da Random Forest model značajno nadmašuje Ridge regresiju, ostvarujući manju pogrešku i osjetno veću točnost predikcije. U konačnici, rad potvrđuje kako modeli strojnog učenja mogu uspješno prepoznati i modelirati kompleksne, nelinearne odnose između karakteristika mikrolokacije i same cijene nekretnina.

SADRŽAJ

1. UVOD	1
2. RELATED WORK.....	2
3. PODACI.....	3
3.1 Izvor podataka.....	3
3.2 Opis atributa.....	3
4. METODOLOGIJA.....	4
4.1 Priprema i predprocesiranje podataka	4
4.2 Exploratory Data Analysis (EDA).....	4
4.3 Podjela podataka i skaliranje	9
4.4 Modeli strojnog učenja	10
4.4.1 Ridge regresija	10
4.4.1 Random Forest regresija.....	10
4.5 Evaluacija modela	10
5. EKSPERIMENTI.....	11
6. REZULTATI.....	12
7. RASPRAVA	14
8. ZAKLJUČAK.....	15
9. SLIKE	16
10. LITERATURA.....	17

1. UVOD

Predviđanje cijena nekretnina jedan je od najčešćih problema u analizi podataka i strojnog učenja, jer ima direktnu primjenu u stvarnom životu. Cijena nekretnine ne ovisi samo o jednoj stvari, nego o velikom broju različitih čimbenika koji zajedno utječu na njezinu vrijednost. Ti čimbenici mogu biti vezani uz lokaciju, stanje okoline, socio-ekonomske uvjete stanovništva, infrastrukturu i druge karakteristike područja.

U stvarnom svijetu procjena vrijednosti nekretnina često se radi ručno ili na temelju jednostavnih pravila, što može dovesti do netočnosti i subjektivnih procjena. Zbog toga se u modernim sustavima sve više koriste metode strojnog učenja koje mogu analizirati velike količine podataka i pronaći obrasce koji nisu odmah vidljivi čovjeku.

Ovaj projekt temelji se na analizi skupa podataka Boston Housing Dataset koji sadrži informacije o različitim karakteristikama područja Bostona. Svaki zapis u skupu podataka opisuje jedno područje i njegove karakteristike poput stope kriminala, prosječnog broja soba u kućama, udaljenosti od centara grada i drugih socio-ekonomskih pokazatelja.

Cilj ovog rada je bolje razumjeti kako različite varijable utječu na cijenu nekretnina te kako se ti odnosi mogu prikazati pomoću modela strojnog učenja. Posebna pažnja posvećena je analizi podataka i razumijevanju njihovih odnosa prije samog modeliranja.

U okviru rada korištene su osnovne metode obrade podataka, uključujući čišćenje, pregled statistike i analizu odnosa između varijabli. Nakon toga su primijenjeni modeli strojnog učenja koji uče iz podataka i pokušavaju predvidjeti vrijednost nekretnina na temelju ulaznih značajki.

Ovaj rad pokazuje kako se uz pomoć suvremenih metoda može bolje razumjeti kompleksnost tržišta nekretnina te kako podaci mogu pomoći u donošenju boljih odluka.

2. RELATED WORK

Predviđanje cijena nekretnina u literaturi se najčešće promatra kao regresijski problem u kojem se analiziraju odnosi između više ulaznih varijabli i jedne kontinuirane izlazne vrijednosti. Ovaj tip problema koristi se kao standardni primjer u nadziranom učenju zbog svoje jednostavne formulacije, ali i složenih odnosa koji se mogu pojaviti u podacima.

U ranim pristupima analizi podataka najčešće su se koristili linearni modeli koji pretpostavljaju proporcionalne odnose između varijabli. Iako takvi modeli imaju prednost interpretabilnosti, njihova primjena je ograničena kada podaci sadrže nelinearne obrasce i kompleksne interakcije između varijabli.

Razvojem strojnog učenja sve se više koriste modeli temeljeni na stablima odlučivanja, koji ne zahtijevaju pretpostavku linearne veze između varijabli. Ansambl metode, poput Random Forest pristupa, kombiniraju više modela kako bi se poboljšala stabilnost i smanjila pogreška predikcije.

U literaturi se često ističe da usporedba različitih modela predstavlja standardni pristup u evaluaciji regresijskih problema. Time se omogućuje analiza razlika između jednostavnih linearnih modela i kompleksnijih nelinearnih metoda.

3. PODACI

3.1 Izvor podataka

Korišten je Boston Housing Dataset (Understanding Urban Real Estate: The Boston Housing Dataset), koji predstavlja jedan od najpoznatijih skupova podataka u području strojnog učenja za regresijske probleme. Dataset je preuzet iz javno dostupnih repozitorija za analizu podataka i strojno učenje, Kaggle platforme (<https://www.kaggle.com/datasets/arunjangir245/boston-housing-dataset>).

Skup podataka originalno je povezan s istraživanjem tržišta nekretnina u području Bostona te sadrži socio-ekonomske i geografske varijable koje opisuju karakteristike pojedinih urbanih zona.

Dataset se sastoji od jedne tablice podataka u kojoj svaka instanca predstavlja jednu promatranu regiju. Varijable uključuju faktore poput stope kriminala, udjela industrijskih zona, broja soba, poreznih stopa i drugih karakteristika koje utječu na cijenu nekretnina. Ciljna varijabla predstavlja srednju vrijednost nekretnina (MEDV).

3.2 Opis atributa

Originalni skup podataka Boston Housing Dataset sadrži 13 ulaznih varijabli i jednu ciljnu varijablu koja predstavlja srednju vrijednost nekretnina (MEDV). Svaki atribut opisuje socio-ekonomske i fizičke karakteristike promatrane regije.

Atribut	Opis
CRIM	Stopa kriminala po stanovniku
ZN	Udio stambenih zona za velike parcele
INDUS	Udio poslovnih površina
CHAS	Blizina rijeke Charles (1 = da, 0 = ne)
NOX	Koncentracija dušikovih oksida
RM	Prosječan broj soba po stanu
AGE	Udio starih zgrada
DIS	Udaljenost do centara zaposlenja
RAD	Pristupačnost autocestama
TAX	Porezna stopa po nekretnini
PTRATIO	Omjer učenika i učitelja
B	Udio stanovništva afroameričkog podrijetla
LSTAT	Postotak stanovništva nižeg socio-ekonomskog statusa
MEDV	Srednja vrijednost nekretnina (ciljna varijabla)

4. METODOLOGIJA

Metodologija ovog rada obuhvaća nekoliko faza: predprocesiranje podataka, podjelu podataka na skup za učenje i testiranje, primjenu standardizacije te izgradnju i evaluaciju modela strojnog učenja.

4.1 Priprema i predprocesiranje podataka

U prvom koraku izvršena je osnovna analiza kvalitete podataka. Provjereno je postojanje nedostajućih vrijednosti u skupu podataka Boston Housing Dataset. Rezultati su pokazali da u nijednoj varijabli ne nedostaju vrijednosti, što omogućuje izravnu primjenu modela bez potrebe za dodatnim imputacijama.

Nakon toga izvršena je osnovna statistička analiza podataka (mean, std, min, max) kako bi se dobio uvid u raspodjelu varijabli.

Posebna pažnja posvećena je ciljnoj varijabli MEDV, koja predstavlja srednju vrijednost nekretnina. Analizom je utvrđeno da se većina vrijednosti nalazi u rasponu 17–25 (u tisućama dolara), uz prisutnost ekstremnih vrijednosti (outliera) koji dosežu maksimalnu vrijednost 50.

4.2 Exploratory Data Analysis (EDA)


U ovom dijelu rada napravljena je osnovna analiza podataka kako bi se bolje razumjelo kako izgleda skup podataka i kakvi se odnosi nalaze između varijabli. Prvo je proučavana ciljna varijabla MEDV, koja predstavlja cijenu kuća. To je napravljeno pomoću histograma i boxplota, koji prikazuju kako su vrijednosti raspoređene.

Na temelju tih grafova može se vidjeti da se većina cijena kuća nalazi u srednjem rasponu, dok manji broj vrijednosti odstupa i ide prema višim ili nižim cijenama. Također se vidi da distribucija nije potpuno ravnomjerna, nego postoji blaga asimetrija, što znači da su neke vrijednosti češće od drugih.

Nakon toga je analizirano kako su pojedine ulazne varijable povezane s cijenom kuća. To je napravljeno pomoću korelacije, koja pokazuje koliko je neka varijabla povezana s promjenom cijene. Rezultati su pokazali da varijabla RM (prosječan broj soba) ima najjaču pozitivnu vezu s cijenom, što znači da kuće s više soba uglavnom imaju veću cijenu.


S druge strane, varijabla LSTAT (udio stanovništva nižeg socio-ekonomskog statusa) ima najjaču negativnu vezu s cijenom, što znači da su cijene kuća obično niže u područjima gdje je taj udio veći.

Na kraju je prikazan i odnos između RM i MEDV pomoću scatter grafa. Taj graf pokazuje jasan trend da s povećanjem broja soba raste i cijena kuće, što potvrđuje da je ta varijabla vrlo važna za predviđanje cijena.




Slika 1. Distribucija cijena kuća MEDV

Može se uočiti da se većina vrijednosti nalazi u rasponu srednjih cijena, dok je manji broj nekretnina s višim vrijednostima. Distribucija je blago asimetrična, što ukazuje na prisutnost ekstremnih vrijednosti (outliera) na višem kraju raspona.




Slika 2. Distribucija cijena kuća i outlieri (MEDV)

Može se uočiti prisutnost većeg broja outliera, posebno na višem kraju distribucije, gdje se vrijednosti približavaju maksimalnoj granici od 50. Također se vidi da su većina vrijednosti koncentrirane u srednjem rasponu, dok manji broj odstupa od uobičajenih vrijednosti.




Slika 3. Korelacija varijabli s MEDV (cijenom kuće)

Može se uočiti da varijabla RM ima najjaču pozitivnu korelaciju s cijenom kuća, dok LSTAT ima najjaču negativnu korelaciju. Ostale varijable imaju slabiji ili umjereni utjecaj na cijenu nekretnina.




Slika 4. Utjecaj socioekonomskog statusa (LSTAT) na cijenu kuće (MEDV)

Grafikon prikazuje odnos između udjela stanovništva nižeg socioekonomskog statusa (LSTAT) i cijene nekretnina (MEDV), jasno ukazujući na snažnu negativnu korelaciju. Crvena regresijska linija potvrđuje izražen silazni trend, što znači da cijene kuća značajno opadaju u četvrtima s većim postotkom siromašnijeg stanovništva. Na samom vrhu uočljivo je i umjetno ograničenje podataka, gdje je maksimalna vrijednost nekretnina fiksirana na 50 tisuća dolara.




Slika 5. Utjecaj broja soba (RM) na cijenu kuće

Grafikon prikazuje odnos između prosječnog broja soba po stambenoj jedinici (RM) i cijene nekretnina (MEDV), ukazujući na snažnu pozitivnu korelaciju. Crvena regresijska linija jasno potvrđuje uzlazni trend koji pokazuje da veći broj soba izravno utječe na rast vrijednosti kuća. Prema tablici, prosječan broj soba iznosi oko 6.28 (uz medijalnu cijenu od 22.53 tisuće dolara), dok se na vrhu ponovno uočava skupina nekretnina s maksimalnom, ograničenom vrijednošću od 50 tisuća dolara bez obzira na veličinu.



Slika 6. Utjecaj blizine rijeke (CHAS) na cijenu kuće

Grafikon kroz box plot uspoređuje cijene nekretnina ovisno o njihovoj poziciji uz rijeku Charles (CHAS). Vidljivo je da nekretnine s pogledom na rijeku (CHAS = 1) imaju primjetno višu medijalnu vrijednost i općenito pomaknut cjenovni razred prema gore u odnosu na ostale lokacije. Iako je broj kuća uz samu rijeku statistički znatno manji (što potvrđuje podatak da je prosjek varijable CHAS svega 0.069), blizina vode jasno djeluje kao luksuzni faktor koji podiže donju i gornju granicu cijene kvartala.



Slika 7. Utjecaj varijabli na cijenu kuće (korelacija s MEDV)

Grafikon i pripadajuća tablica prikazuju cjelovit pregled koeficijenata linearne korelacije svih nezavisnih varijabli u odnosu na ciljnu vrijednost nekretnina (MEDV). Vizualizacija jasno identificira prosječan broj soba (RM, 0.70) kao dominantan pozitivan čimbenik, dok socioekonomski status (LSTAT, -0.74) i omjer učenika i nastavnika (PTRATIO, -0.51) predvode skupinu varijabli s izraženim negativnim utjecajem. Ovakav raspored korelacija sugerira da će linearni modeli primarno hvatati utjecaj prostranosti objekta i socijalne komponente kvarta, dok varijable poput blizine rijeke (CHAS) i starosti objekata (AGE) imaju sekundarni značaj u linearnom kontekstu.

4.3 Podjela podataka i skaliranje

U ovom koraku skup podataka je podijeljen na dva dijela: trening i test skup. Podjela je napravljena u omjeru 80% podataka za učenje modela i 20% podataka za testiranje.

Trening skup se koristi za to da model “uči” iz podataka, odnosno da pronalazi odnose između ulaznih varijabli i cijene kuća. Test skup se koristi kasnije kako bi se provjerilo koliko dobro model radi na novim, neviđenim podacima koje nije vidio tijekom učenja. Na taj način se dobiva realnija procjena kvalitete modela.

Nakon podjele podataka napravljena je i standardizacija ulaznih varijabli pomoću metode StandardScaler. To znači da su sve varijable pretvorene u istu skalu, kako bi imale sličan raspon vrijednosti. Ovo je važno jer neki modeli bolje rade kada su svi ulazni podaci na istoj razini.

Važno je napomenuti da se standardizacija računa samo na temelju trening skupa, a zatim se ista transformacija primjenjuje i na test skup. Time se izbjegava “curenje informacija”, odnosno situacija u kojoj bi model slučajno dobio informacije iz test podataka tijekom učenja, što bi moglo dati dobre rezultate.

4.4 Modeli strojnog učenja

4.1.1 Ridge regresija

Kao osnovni model korištena je Ridge regresija. To je jednostavan linearni model koji pokušava pronaći vezu između ulaznih varijabli i cijene kuća. Ovaj model se često koristi kao početna točka jer je lagan za razumjeti i daje osnovnu usporedbu za druge, naprednije modele.

4.2.1 Random Forest regresija

Uz njega je korišten i Random Forest model. To je napredniji model koji se temelji na više stabala odlučivanja. Svako stablo daje svoju procjenu, a konačni rezultat dobije se kombinacijom svih tih procjena. Zbog toga ovaj model bolje hvata složenije odnose u podacima, posebno kada veze između varijabli nisu jednostavne i linearne.

4.5 Evaluacija modela

Metrika	Opis
RMSE (Root Mean Squared Error)	Mjeri prosječnu pogrešku predikcije. Veće greške više kažnjava nego male, pa je osjetljiv na veća odstupanja.
MAE (Mean Absolute Error)	Prikazuje prosječnu apsolutnu razliku između stvarnih i predviđenih vrijednosti. Lakše se interpretira jer je u istoj jedinici kao i ciljna varijabla.
R² (koeficijent determinacije)	Pokazuje koliko dobro model objašnjava varijabilnost podataka. Vrijednosti bliže 1 znače bolji model.

5. EKSPERIMENTI

5.1. Opis eksperimenata

Eksperimentalni dio rada proveden je u Jupyter Notebook okruženju koristeći Python i biblioteku Scikit-Learn.

Modeli su trenirani na istom skupu podataka, pri čemu je korišten standardni omjer podjele 80% za učenje i 20% za testiranje. Na taj način osigurana je dosljedna i objektivna usporedba performansi modela.

U eksperimentu su korištena dva regresijska modela: Ridge regresija kao linearni pristup te Random Forest regresija kao nelinearni ansambl model.

Kod Random Forest modela korišteno je 100 stabala odlučivanja (`n_estimators=100`), dok je Ridge regresija korištena kao osnovni model bez dodatnih kompleksnih podešavanja, s ciljem usporedbe osnovnog linearnog i naprednijeg nelinearnog pristupa.

Svi modeli evaluirani su na istom test skupu podataka kako bi se rezultati mogli direktno usporediti.

5.2. Evaluacijske metrike

Za evaluaciju modela korištene su standardne regresijske metrike: MAE, RMSE i R^2 , koje omogućuju procjenu točnosti predikcija i usporedbu performansi modela.

6. REZULTATI

6.1 Usporedba modela


Model	RMSE	MAE	R ²
Ridge regresija	4.93	3.19	0.67
Random Forest	2.95	2.04	0.88

Rezultati pokazuju jasnu razliku u performansama između modela. Random Forest regresija postiže znatno niže vrijednosti pogreške (RMSE i MAE) u odnosu na Ridge regresiju, što ukazuje na preciznije predikcije cijena nekretnina.

Također, koeficijent determinacije (R^2) je viši kod Random Forest modela, što znači da ovaj model bolje objašnjava varijabilnost podataka i uspješnije uči kompleksne odnose između ulaznih varijabli i ciljane vrijednosti.


6.2 Grafovi usporedbe modela

Graf prikazuje odnos između stvarnih i predviđenih cijena kuća kod Ridge regresije. Crvena dijagonalna linija predstavlja idealnu predikciju, odnosno situaciju u kojoj bi model potpuno točno predvidio vrijednost nekretnine. Može se primijetiti da dio predikcija odstupa od idealne linije, posebno kod viših cijena kuća, što ukazuje na određenu pogrešku modela. Ipak, vidljiv je opći linearni trend, što potvrđuje da model uspijeva prepoznati osnovne odnose između varijabli i cijene nekretnina.



Slika 8. Ridge regresija

Graf prikazuje usporedbu stvarnih i predviđenih cijena pomoću Random Forest modela. Većina točaka nalazi se bliže idealnoj liniji u odnosu na Ridge regresiju, što pokazuje da model daje preciznije procjene cijena nekretnina. Random Forest bolje prepoznaje složenije i nelinearne odnose između varijabli, zbog čega ostvaruje manju pogrešku i veću točnost predikcije. Unatoč tome, vidljiva su manja odstupanja kod ekstremnih vrijednosti, što je očekivano kod stvarnih podataka.



Slika 9. Random Forest

Usporedbom grafova može se vidjeti da Random Forest model daje predikcije koje su bliže stvarnim vrijednostima u odnosu na Ridge regresiju. To potvrđuju i evaluacijske metrike, gdje Random Forest ostvaruje manji RMSE i MAE te veći R^2 koeficijent.

7. RASPRAVA

Rezultati dobiveni tijekom eksperimenta pokazuju da modeli strojnog učenja mogu uspješno predviđati cijene nekretnina na temelju različitih socio-ekonomskih i geografskih varijabli. Usporedbom korištenih modela vidljivo je da je Random Forest ostvario bolje rezultate od Ridge regresije u svim evaluacijskim metrikama.

Ridge regresija pokazala se kao dobar osnovni linearni model jer uspijeva prepoznati glavne trendove u podacima. Prednost ovog modela je njegova jednostavnost i lakša interpretacija rezultata. Međutim, budući da se temelji na linearnim odnosima između varijabli, model teže prepoznaje složenije obrasce u podacima, zbog čega dolazi do većih odstupanja kod pojedinih predikcija.

S druge strane, Random Forest model ostvario je značajno bolju preciznost predviđanja. Razlog tome je što koristi više stabala odlučivanja i može uspješnije modelirati nelinearne odnose između varijabli. Model je pokazao manju pogrešku i bolje prilagodio stvarnim vrijednostima cijena nekretnina.

Unatoč dobrim rezultatima, postoje i određena ograničenja ovog rada. Boston Housing Dataset predstavlja relativno mali skup podataka te ne uključuje neke moderne čimbenike koji danas mogu utjecati na cijene nekretnina, poput energetske učinkovitosti, stanja tržišta ili detaljnijih lokacijskih informacija. Također, dio vrijednosti u datasetu umjetno je ograničen maksimalnom vrijednošću od 50, što može utjecati na točnost modela kod skupljih nekretnina.

Općenito, rezultati rada potvrđuju da napredniji modeli strojnog učenja mogu uspješno prepoznati obrasce u podacima i pružiti vrlo dobre procjene cijena nekretnina.

8. ZAKLJUČAK

U ovom radu analiziran je problem predviđanja cijena nekretnina pomoću metoda strojnog učenja na primjeru Boston Housing Dataset skupa podataka. Tijekom rada provedena je analiza i priprema podataka, istraživanje odnosa između varijabli te izgradnja i usporedba različitih modela za regresiju.

Rezultati su pokazali da socio-ekonomski i geografski čimbenici imaju značajan utjecaj na cijenu nekretnina. Posebno su se izdvojile varijable RM i LSTAT, koje su pokazale najjaču povezanost s ciljnom varijablom MEDV.

U eksperimentalnom dijelu rada uspoređeni su Ridge regresija i Random Forest model. Random Forest ostvario je bolje rezultate u svim evaluacijskim metrikama, uz manju pogrešku predikcije i veći koeficijent determinacije. Time je potvrđeno da nelinearni modeli mogu uspješnije opisati složene odnose prisutne u podacima.

Kroz rad je prikazano kako metode strojnog učenja mogu pomoći u analizi tržišta nekretnina i predviđanju cijena na temelju dostupnih podataka. Takvi modeli mogu imati korisnu primjenu u financijama, procjeni vrijednosti nekretnina i sustavima za podršku odlučivanju.

Kao mogući smjer budućih istraživanja, model bi se mogao proširiti korištenjem većih i modernijih skupova podataka koji uključuju dodatne informacije o lokaciji, stanju objekta i tržišnim uvjetima. Također, mogla bi se ispitati primjena naprednijih modela poput XGBoost, Gradient Boosting ili neuronskih mreža kako bi se dodatno poboljšala točnost predikcije.

9. SLIKE

Slika 1. Distribucija cijena kuća MEDV.....	5
Slika 2. Distribucija cijena kuća i outlieri (MEDV)	5
Slika 3. Korelacija varijabli s MEDV (cijenom kuće)	6
Slika 4. Utjecaj socioekonomskog statusa (LSTAT) na cijenu kuće (MEDV)	6
Slika 5. Utjecaj broja soba (RM) na cijenu kuće	7
Slika 6. Utjecaj blizine rijeke (CHAS) na cijenu kuće.....	8
Slika 7. Utjecaj varijabli na cijenu kuće (korelacija s MEDV).....	9
Slika 8. Ridge regresija.....	12
Slika 9. Random Forest.....	13

10.LITERATURA

1. Boston Housing Dataset. Kaggle platforma.
<https://www.kaggle.com/datasets/arunjangir245/boston-housing-dataset>
2. Scikit-Learn Documentation.
<https://scikit-learn.org/stable/>
3. Scikit-Learn – Supervised Learning Documentation.
https://scikit-learn.org/stable/supervised_learning.html
4. Géron, A. *Hands-On Machine Learning with Scikit-Learn, Keras & TensorFlow*. O'Reilly Media, 2022.